

01_Alzheimer_cognitive_cell

August 28, 2025

```
[1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
from sklearn.model_selection import train_test_split, GridSearchCV, \
    StratifiedKFold
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestClassifier
from sklearn.feature_selection import SelectKBest, f_classif
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.metrics import (accuracy_score, precision_score, recall_score,
                             f1_score, classification_report, confusion_matrix)

warnings.filterwarnings('ignore')
```

```
[2]: # Charger les données
df = pd.read_csv("alzheimers_disease_data.csv")

# Afficher les informations de base
print("Forme du jeu de données :", df.shape)
print("\n5 Premières lignes :")
print(df.head())

print("\nTypes de données :/")
print(df.dtypes)

print("\nValeurs manquantes par colonne :")
print(df.isnull().sum())
```

Forme du jeu de données : (2149, 35)

5 Premières lignes :

	PatientID	Age	Gender	Ethnicity	EducationLevel	BMI	Smoking	\
0	4751	73	0	0	2	22.927749	0	
1	4752	89	0	0	0	26.827681	0	
2	4753	73	0	3	1	17.795882	0	

3	4754	74	1	0	1	33.800817	1
4	4755	89	0	0	0	20.716974	0

	AlcoholConsumption	PhysicalActivity	DietQuality	...	MemoryComplaints	\
0	13.297218	6.327112	1.347214	...		0
1	4.542524	7.619885	0.518767	...		0
2	19.555085	7.844988	1.826335	...		0
3	12.209266	8.428001	7.435604	...		0
4	18.454356	6.310461	0.795498	...		0

	BehavioralProblems	ADL	Confusion	Disorientation	\
0	0	1.725883	0	0	
1	0	2.592424	0	0	
2	0	7.119548	0	1	
3	1	6.481226	0	0	
4	0	0.014691	0	0	

	PersonalityChanges	DifficultyCompletingTasks	Forgetfulness	Diagnosis	\
0	0		1	0	0
1	0		0	1	0
2	0		1	0	0
3	0		0	0	0
4	1		1	0	0

	DoctorInCharge
0	XXXConfid
1	XXXConfid
2	XXXConfid
3	XXXConfid
4	XXXConfid

[5 rows x 35 columns]

Types de données :/n

PatientID	int64
Age	int64
Gender	int64
Ethnicity	int64
EducationLevel	int64
BMI	float64
Smoking	int64
AlcoholConsumption	float64
PhysicalActivity	float64
DietQuality	float64
SleepQuality	float64
FamilyHistoryAlzheimers	int64
CardiovascularDisease	int64
Diabetes	int64

Depression	int64
HeadInjury	int64
Hypertension	int64
SystolicBP	int64
DiastolicBP	int64
CholesterolTotal	float64
CholesterolLDL	float64
CholesterolHDL	float64
CholesterolTriglycerides	float64
MMSE	float64
FunctionalAssessment	float64
MemoryComplaints	int64
BehavioralProblems	int64
ADL	float64
Confusion	int64
Disorientation	int64
PersonalityChanges	int64
DifficultyCompletingTasks	int64
Forgetfulness	int64
Diagnosis	int64
DoctorInCharge	object
dtype:	object

Valeurs manquantes par colonne :

PatientID	0
Age	0
Gender	0
Ethnicity	0
EducationLevel	0
BMI	0
Smoking	0
AlcoholConsumption	0
PhysicalActivity	0
DietQuality	0
SleepQuality	0
FamilyHistoryAlzheimers	0
CardiovascularDisease	0
Diabetes	0
Depression	0
HeadInjury	0
Hypertension	0
SystolicBP	0
DiastolicBP	0
CholesterolTotal	0
CholesterolLDL	0
CholesterolHDL	0
CholesterolTriglycerides	0
MMSE	0

```
FunctionalAssessment      0
MemoryComplaints          0
BehavioralProblems        0
ADL                        0
Confusion                  0
Disorientation             0
PersonalityChanges         0
DifficultyCompletingTasks  0
Forgetfulness              0
Diagnosis                  0
DoctorInCharge             0
dtype: int64
```

```
[3]: # Supprimer les colonnes inutiles
df_clean = df.drop(['PatientID', 'DoctorInCharge'], axis=1)

print(f"Forme du jeu de données après nettoyage : {df_clean.shape}")
print("\nJeu de données nettoyé :")
print(df_clean.head())
```

Forme du jeu de données après nettoyage : (2149, 33)

Jeu de données nettoyé :

	Age	Gender	Ethnicity	EducationLevel	BMI	Smoking	\
0	73	0	0	2	22.927749	0	
1	89	0	0	0	26.827681	0	
2	73	0	3	1	17.795882	0	
3	74	1	0	1	33.800817	1	
4	89	0	0	0	20.716974	0	

	AlcoholConsumption	PhysicalActivity	DietQuality	SleepQuality	...	\
0	13.297218	6.327112	1.347214	9.025679	...	
1	4.542524	7.619885	0.518767	7.151293	...	
2	19.555085	7.844988	1.826335	9.673574	...	
3	12.209266	8.428001	7.435604	8.392554	...	
4	18.454356	6.310461	0.795498	5.597238	...	

	FunctionalAssessment	MemoryComplaints	BehavioralProblems	ADL	\
0	6.518877	0	0	1.725883	
1	7.118696	0	0	2.592424	
2	5.895077	0	0	7.119548	
3	8.965106	0	1	6.481226	
4	6.045039	0	0	0.014691	

	Confusion	Disorientation	PersonalityChanges	DifficultyCompletingTasks	\
0	0	0	0	1	
1	0	0	0	0	
2	0	1	0	1	

3	0	0	0	0
4	0	0	1	1

	Forgetfulness	Diagnosis
0	0	0
1	1	0
2	0	0
3	0	0
4	0	0

[5 rows x 33 columns]

```
[4]: def detect_outliers_iqr(dataframe):
    """
    Détecter les valeurs aberrantes en utilisant la méthode de l'écart_
    ↳ interquartile (IQR)
    """
    outlier_indices = []

    for col in dataframe.columns[:-1]: # Sans la colonne cible
        Q1 = dataframe[col].quantile(0.25)
        Q3 = dataframe[col].quantile(0.75)
        IQR = Q3 - Q1
        outlier_step = 1.5 * IQR

        outliers = dataframe[
            (dataframe[col] < Q1 - outlier_step) |
            (dataframe[col] > Q3 + outlier_step)
        ].index

        outlier_indices.extend(outliers)

    return list(set(outlier_indices))

# Détecter les valeurs aberrantes
outlier_indices = detect_outliers_iqr(df_clean)
print(f"Nombre de valeurs aberrantes détectées : {len(outlier_indices)}")
```

Nombre de valeurs aberrantes détectées : 1895

```
[5]: def plot_feature_distributions(dataframe, target_column='Diagnosis',
    ↳ figsize=(40, 45)):
    """
    Trace la distribution avec hue.
    """
    feature_cols = [col for col in dataframe.columns if col != target_column]
    n_features = len(feature_cols)
    n_cols = 3
```

```

n_rows = (n_features // n_cols) + (1 if n_features % n_cols != 0 else 0)

palette = sns.color_palette("Set2") # même palette que l'histogramme
value_to_color = dict(zip(sorted(dataframe[target_column].unique()),
↪palette))

fig = plt.figure(figsize=figsize)

for idx, col in enumerate(feature_cols, start=1):
    ax = plt.subplot(n_rows, n_cols, idx)

    # Histogramme
    sns.histplot(
        data=dataframe,
        x=col,
        hue=target_column,
        kde=True,
        palette=value_to_color,
        alpha=0.5,
        ax=ax,
        multiple='stack'
    )

    # Lignes de moyenne et médiane
    for target_value, color in value_to_color.items():
        subset = dataframe[dataframe[target_column] == target_value]
        mean_val = np.mean(subset[col])
        median_val = np.median(subset[col])

        ax.axvline(
            mean_val,
            color=color,
            linestyle='--',
            linewidth=2,
            label=f"{target_column}={target_value} (moyenne)"
        )
        ax.axvline(
            median_val,
            color=color,
            linestyle='-',
            linewidth=2,
            label=f"{target_column}={target_value} (médiane)"
        )

    ax.set_title(f'Distribution de {col}')
    # Fusionner les légendes
    handles, labels = ax.get_legend_handles_labels()


```

```
ax.legend(handles, labels, title=f"{target_column}")
```

```
plt.tight_layout()
plt.show()
```

Tracer les distributions

```
plot_feature_distributions(df_clean)
```



```
[6]: # Séparer les caractéristiques et la cible
X = df_clean.drop(columns=['Diagnosis'])
y = df_clean['Diagnosis']

# Analyser la distribution des classes
unique_classes, class_counts = np.unique(y, return_counts=True)
print("\nDistribution des classes :")
for cls, count in zip(unique_classes, class_counts):
    print(f"Classe : {cls} | Nombre : {count}")
```

Distribution des classes :
 Classe : 0 | Nombre : 1389
 Classe : 1 | Nombre : 760

```
[7]: # Diviser les données
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y
)

# Standardiser les caractéristiques
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# Convertir en DataFrames
X_train_scaled_df = pd.DataFrame(X_train_scaled, columns=X_train.columns)
X_test_scaled_df = pd.DataFrame(X_test_scaled, columns=X_test.columns)

print(f"Forme de l'ensemble d'entraînement : {X_train_scaled_df.shape}")
print(f"Forme de l'ensemble de test : {X_test_scaled_df.shape}")
```

Forme de l'ensemble d'entraînement : (1719, 32)
 Forme de l'ensemble de test : (430, 32)

```
[8]: # Matrice de corrélation
corr_matrix = X_train_scaled_df.join(y_train).corr()

# Plot la matrice des corrélations
plt.figure(figsize=(20, 15))
sns.heatmap(corr_matrix, annot=False, cmap='coolwarm')
plt.title("Matrice de corrélation entre caractéristiques et cible")
plt.show()

# Identifier les caractéristiques corrélées avec la cible
correlated_features = corr_matrix[abs(corr_matrix['Diagnosis']) > 0.1].index.
    ↪tolist()
if 'Diagnosis' in correlated_features:
```




```

correlated_features.remove('Diagnosis')

print("\nCaractéristiques corrélées avec la cible (|corrélacion| > 0.1) :")
print(correlated_features)

```



Caractéristiques corrélées avec la cible ($|corrélacion| > 0.1$) :

[]

```

[9]: # Importance des caractéristiques avec Random Forest
rf_selector = RandomForestClassifier(n_estimators=100)
rf_selector.fit(X_train_scaled_df, y_train)

feature_importances = pd.Series(rf_selector.feature_importances_,
                                index=X_train.columns).
    ↪sort_values(ascending=False)


```

```

# Plot l'importance des caractéristiques
plt.figure(figsize=(10, 15))
sns.barplot(x=feature_importances.values, y=feature_importances.index)
plt.title("Importance des caractéristiques (Random Forest)")
plt.xlabel("Importance")
plt.ylabel("Caractéristiques")
plt.show()

# Sélectionner les caractéristiques importantes (seuil > 0.02)
selected_features_rf = feature_importances[feature_importances > 0.02].index.
    ↳ tolist()
print("\nCaractéristiques sélectionnées par l'importance Random Forest :")
print(selected_features_rf)

```



Caractéristiques sélectionnées par l'importance Random Forest :


```
['FunctionalAssessment', 'ADL', 'MMSE', 'MemoryComplaints',
'BehavioralProblems', 'CholesterolTriglycerides', 'PhysicalActivity',
'AlcoholConsumption', 'SleepQuality', 'CholesterolHDL', 'DietQuality',
'CholesterolTotal', 'CholesterolLDL', 'BMI', 'DiastolicBP', 'SystolicBP', 'Age']
```

```
[10]: # Test F ANOVA pour la sélection des caractéristiques
selector_anova = SelectKBest(score_func=f_classif, k='all')
selector_anova.fit(X_train_scaled_df, y_train)

# Scores des caractéristiques
feature_scores = pd.Series(selector_anova.scores_,
                           index=X_train.columns).sort_values(ascending=False)

# Plot les scores ANOVA
plt.figure(figsize=(10, 15))
sns.barplot(x=feature_scores.values, y=feature_scores.index)
plt.title("Scores des caractéristiques (Test F ANOVA)")
plt.xlabel("Score")
plt.ylabel("Caractéristiques")
plt.show()

# Sélectionner les caractéristiques avec des scores ANOVA élevés
selected_features_anova = feature_scores[feature_scores > 10].index.tolist()
print("\nCaractéristiques sélectionnées par ANOVA :")
print(selected_features_anova)
```



Caractéristiques sélectionnées par ANOVA :

```
['FunctionalAssessment', 'MemoryComplaints', 'ADL', 'MMSE',
'BehavioralProblems']
```

```
[11]: # Combiner toutes les caractéristiques sélectionnées
selected_features = list(set(correlated_features + selected_features_rf +
    ↪selected_features_anova))
print("\nCaractéristiques finales sélectionnées :")
print(selected_features)

# Appliquer la sélection des caractéristiques
X_train_selected = X_train_scaled_df[selected_features]
X_test_selected = X_test_scaled_df[selected_features]

print(f"\nForme des caractéristiques sélectionnées - Entraînement :↵
    ↪{X_train_selected.shape}")
print(f"Forme des caractéristiques sélectionnées - Test : {X_test_selected.
    ↪shape}")
```

Caractéristiques finales sélectionnées :

```
['MMSE', 'ADL', 'SleepQuality', 'DietQuality', 'CholesterolHDL',
'CholesterolLDL', 'SystolicBP', 'Age', 'FunctionalAssessment',
'CholesterolTriglycerides', 'DiastolicBP', 'BehavioralProblems',
'PhysicalActivity', 'BMI', 'CholesterolTotal', 'MemoryComplaints',
'AlcoholConsumption']
```

Forme des caractéristiques sélectionnées - Entraînement : (1719, 17)

Forme des caractéristiques sélectionnées - Test : (430, 17)

```
[12]: # Définir les modèles
models = {
    'Régression Logistique': LogisticRegression(max_iter=10000),
    'Forêt Aléatoire': RandomForestClassifier(),
    'SVM': SVC(probability=True)
}

# Stockage des résultats
results = {}

def evaluate_model(model_name, model, X_train, y_train, X_test, y_test):
    """
    Évaluer les modèles
    """
    # Entraîner le modèle
    model.fit(X_train, y_train)

    # Prédiction
    y_pred = model.predict(X_test)

    # Calculer les métriques
```

```

accuracy = accuracy_score(y_test, y_pred)
precision = precision_score(y_test, y_pred)
recall = recall_score(y_test, y_pred)
f1 = f1_score(y_test, y_pred)

# Stocker les résultats
results[model_name] = {
    'model': model,
    'accuracy': accuracy,
    'precision': precision,
    'recall': recall,
    'f1': f1,
    'classification_report': classification_report(y_test, y_pred),
    'confusion_matrix': confusion_matrix(y_test, y_pred)
}

# Afficher les résultats
print(f"\nRésultats pour {model_name} :")
print(f"Accuracy : {accuracy:.4f}")
print(f"Précision : {precision:.4f}")
print(f"Rappel : {recall:.4f}")
print(f"Score F1 : {f1:.4f}")
print(f"\nRapport de classification :")
print(results[model_name]['classification_report'])
print(f"\nMatrice de confusion :")
print(results[model_name]['confusion_matrix'])

```

```

[13]: # Évaluer chaque modèle
for model_name, model in models.items():
    print(f"\nEntraînement et évaluation de {model_name}")
    evaluate_model(model_name, model, X_train_selected, y_train,
                   X_test_selected, y_test)

```

Entraînement et évaluation de Régression Logistique

Résultats pour Régression Logistique :

Accuracy : 0.8465
 Précision : 0.8209
 Rappel : 0.7237
 Score F1 : 0.7692

Rapport de classification :

	precision	recall	f1-score	support
0	0.86	0.91	0.89	278
1	0.82	0.72	0.77	152

accuracy			0.85	430
macro avg	0.84	0.82	0.83	430
weighted avg	0.84	0.85	0.84	430

Matrice de confusion :

```
[[254  24]
 [ 42 110]]
```

Entraînement et évaluation de Forêt Aléatoire

Résultats pour Forêt Aléatoire :

Accuracy : 0.9372
 Précision : 0.9371
 Rappel : 0.8816
 Score F1 : 0.9085

Rapport de classification :

	precision	recall	f1-score	support
0	0.94	0.97	0.95	278
1	0.94	0.88	0.91	152
accuracy			0.94	430
macro avg	0.94	0.92	0.93	430
weighted avg	0.94	0.94	0.94	430

Matrice de confusion :

```
[[269   9]
 [ 18 134]]
```

Entraînement et évaluation de SVM

Résultats pour SVM :

Accuracy : 0.8581
 Précision : 0.8370
 Rappel : 0.7434
 Score F1 : 0.7875

Rapport de classification :

	precision	recall	f1-score	support
0	0.87	0.92	0.89	278
1	0.84	0.74	0.79	152
accuracy			0.86	430
macro avg	0.85	0.83	0.84	430

weighted avg	0.86	0.86	0.86	430
--------------	------	------	------	-----

Matrice de confusion :

```
[[256  22]
 [ 39 113]]
```

```
[14]: # Grilles de paramètres pour l'optimisation
param_grids = {
    'Régression Logistique': {
        'C': [0.001, 0.01, 0.1, 1, 10, 100],
        'penalty': ['l2']
    },
    'Forêt Aléatoire': {
        'n_estimators': [50, 100, 200],
        'max_depth': [None, 10, 20, 30],
        'min_samples_split': [2, 5, 10],
        'min_samples_leaf': [1, 2, 4]
    },
    'SVM': {
        'C': [0.1, 1, 10, 100],
        'kernel': ['linear', 'rbf'],
        'gamma': ['scale', 'auto', 0.1, 1, 10]
    }
}

def optimize_hyperparameters(model_name, model, param_grid, X_train, y_train):
    """
    Optimiser les hyperparamètres en utilisant GridSearchCV
    """
    print(f"\nOptimisation des hyperparamètres pour {model_name}")

    # Validation croisée stratifiée
    cv = StratifiedKFold(n_splits=5, shuffle=True)

    # GridSearchCV
    grid_search = GridSearchCV(
        estimator=model,
        param_grid=param_grid,
        scoring='f1',
        cv=cv,
        n_jobs=-1,
        verbose=1
    )

    # Ajuster sur les données d'entraînement
    grid_search.fit(X_train, y_train)
```

```

# Extraire les résultats
best_params = grid_search.best_params_
best_score = grid_search.best_score_
best_model = grid_search.best_estimator_

# Stocker les résultats
results[model_name]['best_params'] = best_params
results[model_name]['best_score'] = best_score
results[model_name]['best_model'] = best_model

# Afficher les résultats
print(f"Meilleurs paramètres : {best_params}")
print(f"Meilleur score F1 : {best_score:.4f}")

return best_model

```

```

[15]: # Optimiser chaque modèle
for model_name, model in models.items():
    best_model = optimize_hyperparameters(
        model_name, model, param_grids[model_name],
        X_train_selected, y_train
    )

    # Ré-évaluer le modèle optimisé
    print(f"\nRé-évaluation du {model_name} optimisé")
    evaluate_model(
        f"{model_name} (optimisé)", best_model,
        X_train_selected, y_train, X_test_selected, y_test
    )

```

Optimisation des hyperparamètres pour Régression Logistique
 Fitting 5 folds for each of 6 candidates, totalling 30 fits
 Meilleurs paramètres : {'C': 1, 'penalty': 'l2'}
 Meilleur score F1 : 0.7690

Ré-évaluation du Régression Logistique optimisé

Résultats pour Régression Logistique (optimisé) :
 Accuracy : 0.8465
 Précision : 0.8209
 Rappel : 0.7237
 Score F1 : 0.7692

Rapport de classification :

precision	recall	f1-score	support
-----------	--------	----------	---------

0	0.86	0.91	0.89	278
1	0.82	0.72	0.77	152
accuracy			0.85	430
macro avg	0.84	0.82	0.83	430
weighted avg	0.84	0.85	0.84	430

Matrice de confusion :

```
[[254  24]
 [ 42 110]]
```

Optimisation des hyperparamètres pour Forêt Aléatoire

Fitting 5 folds for each of 108 candidates, totalling 540 fits

Meilleurs paramètres : {'max_depth': None, 'min_samples_leaf': 1, 'min_samples_split': 10, 'n_estimators': 200}

Meilleur score F1 : 0.9301

Ré-évaluation du Forêt Aléatoire optimisé

Résultats pour Forêt Aléatoire (optimisé) :

Accuracy : 0.9395

Précision : 0.9375

Rappel : 0.8882

Score F1 : 0.9122

Rapport de classification :

	precision	recall	f1-score	support
0	0.94	0.97	0.95	278
1	0.94	0.89	0.91	152
accuracy			0.94	430
macro avg	0.94	0.93	0.93	430
weighted avg	0.94	0.94	0.94	430

Matrice de confusion :

```
[[269   9]
 [ 17 135]]
```

Optimisation des hyperparamètres pour SVM

Fitting 5 folds for each of 40 candidates, totalling 200 fits

Meilleurs paramètres : {'C': 1, 'gamma': 'scale', 'kernel': 'rbf'}

Meilleur score F1 : 0.7963

Ré-évaluation du SVM optimisé

Résultats pour SVM (optimisé) :

Accuracy : 0.8581
Précision : 0.8370
Rappel : 0.7434
Score F1 : 0.7875

Rapport de classification :

	precision	recall	f1-score	support
0	0.87	0.92	0.89	278
1	0.84	0.74	0.79	152
accuracy			0.86	430
macro avg	0.85	0.83	0.84	430
weighted avg	0.86	0.86	0.86	430

Matrice de confusion :

```
[[256  22]
 [ 39 113]]
```

```
[16]: # Comparer les modèles optimisés
comparison_data = []

for model_name, result in results.items():
    if 'optimisé' in model_name:
        comparison_data.append({
            'Modèle': model_name,
            'Accuracy': result['accuracy'],
            'Précision': result['precision'],
            'Rappel': result['recall'],
            'Score F1': result['f1']
        })

comparison_df = pd.DataFrame(comparison_data)

print("\nComparaison des modèles optimisés :")
print(comparison_df.round(4))

# Trouver le meilleur modèle
best_model_name = comparison_df.loc[comparison_df['Score F1'].idxmax(),
    ↪ 'Modèle']
print(f"\nMeilleur modèle : {best_model_name}")
print(f"Meilleur score F1 : {comparison_df['Score F1'].max():.4f}")
```

Comparaison des modèles optimisés :

Modèle	Accuracy	Précision	Rappel	Score F1
--------	----------	-----------	--------	----------

0	Régression Logistique (optimisé)	0.8465	0.8209	0.7237	0.7692
1	Forêt Aléatoire (optimisé)	0.9395	0.9375	0.8882	0.9122
2	SVM (optimisé)	0.8581	0.8370	0.7434	0.7875

Meilleur modèle : Forêt Aléatoire (optimisé)

Meilleur score F1 : 0.9122